



重慶對外經貿學院

CHONGQING COLLEGE OF INTERNATIONAL BUSINESS AND ECONOMICS

2025 届本科毕业论文（设计）

题 目

基于单片机的智能秒表的excel数据
可视化系统设计与实现

学 院

大数据与智能工程学院
(工业软件产业学院)

年 级

2021级

专 业

电子科学与技术

学 号

12346

姓 名

张三

指导教师

李四

2025年5月

摘 要

高速发展的互联网在带来便利的同时也衍生出了诸多恶意网页，这些网页时刻影响着网络安全。本文运用Python网络获取技术对URL的特征进行挖掘和提取，最终得到URL字符串特征，HTML代码特征，JavaScript代码特征，HTTP请求特征和Text特征这5类共计85维的URL特征集。并且将这5类特征集相融合，得到用于解释URL信息的征向量。最后使用LogisticRegression，SVC，决策树（ID3，CART），RandomForest这五个二分类算法构建用于识别恶意URL的模型。通过10折交叉验证和消融实验证明了HTTP请求特征和Text特征对识别恶意URL有着积极作用。结果表明，集成学习算法在正确率，准确率，召回率，F1值和AUC值这5项指标上优于传统的机器学习算法，其中随机森林表现最优，AUC值达到0.9940。

关键词：网络安全；网络获取技术；HTTP请求；恶意URL；随机森林

Abstract

The rapid development of the Internet in bringing convenience at the same time also derived a lot of malicious webpages, these pages always affect the network security. This paper uses Python network acquisition technology to mine and extract URL features, and finally gets URL string features, HTML code features, JavaScript code features, HTTP request features and Text features, which are five categories, a total of 85 dimensional URL feature sets. And the five kinds of feature sets are integrated together to form an eigenvector used to interpret the URL information. Finally, five binary classification algorithms, Logistic Regression, SVC, decision tree (ID3, CART) and Random Forest, were used to construct a model for identifying malicious URLs. Through 10-fold cross-validation and ablation experiments, it is proved that HTTP request features and Text features play an active role in identifying malicious URLs. The results show that the integrated learning algorithm is superior to the traditional machine learning algorithm in the accuracy rate, accuracy rate, recall rate, F1 value and AUC value, among which the random forest has the best performance and the AUC value reaches 0.9940.

Keyword: Machine learning; User churn; SMOTE algorithm; Random forests

目 录

1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
2 实验设计与特征提取方法	1
2.1 实验流程	1
2.2 数据获取与介绍	1
2.2.1 URL字符串特征提取	1
2.2.2 HTML代码特征提取	2
2.2.3 JavaScript代码特征提取	3
2.2.4 HTTP请求特征提取	3
2.2.5 Text特征提取	3
3 模型选择与结果分析	3
3.1 特征集划分与模型选择	3
3.2 评估指标	4
4 恶意网页识别系统的设计与实现	4
4.1 系统框架设计	4
4.2 系统的实现	4
4.2.1 设计系统的语言选择	4
4.2.2 系统功能及界面	4
5 总结与展望	4
参考文献	5
附 录	7

1 绪论

1.1 研究背景与意义

1.2 国内外研究现状

2 实验设计与特征提取方法

2.1 实验流程

2.2 数据获取与介绍

2.2.1 URL字符串特征提取

URL是统一资源定位符（Uniform Resource Locator）的缩写，用于指示网络上某个资源的地址。它通常包含协议类型、主机名、文件路径和查询参数等信息，可以用来访问网页、图片、视频等各种网络资源。

基于大量良性和恶意URL的统计观察^[1]，本文选择了六个特征分别为：URL长度、URL域名长度、URL层数、URL中数字的数量、URL中公共字符的数量、URL中特殊字符的数量，并提取这些特征用于模型训练。图2.3显示了所选六个URL特征的分布情况。从图2.3中可以发现，恶意URL和良性URL之间的上述六个特征存在明显的差异。例如，当URL长度在25-75这个区间时，其为良性的概率远大于为恶意的概率，反之则很有可能为恶意URL；对URL的域名长度来说，良性URL的长度经常在15左右，而恶意URL的长度略大于良性URL；URL层数分布也具有明显特征，恶意网页的层数往往很低，大多数在1到2这个区间，而良性网页的层数大多为2到4。




图2.3 URL特征分布情况

2.2.2 HTML代码特征提取

HTML（HyperTextMarkupLanguage）译为超文本标记语言。HTML被广泛应用于Web开发中，是构建Web页面的基础。HTML最初由物理学家TimBerners-Lee在1989年发明，旨在为科学研究机构提供一种共享文档的方式^[5]。随着Web的普及，HTML已成为Web开发的核心技术之一，并不断发展和完善。目前最新版本为HTML5，它引入了许多新特性和API，使得Web应用程序更加强大和交互性更高。HTML的语法简单易学，标签和属性具有良好的可读性。通过使用不同的标签和属性，开发人员可以轻松地创建各种类型的内容和布局。此外，HTML的结构化特性使得搜索引擎对于网页的解析更加容易，从而提高了网站的排名和可访问性。下面是一段最基础的HTML代码块，代码包含了HTML文档的基本结构。

因此，除了URL字符串特征包含识别恶意URL的信息外，其HTML代码也具有相关特征。如：<iframe>标签规定了一个内联框架，其方法如下行代码所示。

```
<iframe src="http://run.com"></iframe>
```

当运行上述代码时，<iframe>标签会加载其内部所包含的页面，若此标签所嵌入的页面具有恶意行为，那么用户的计算机很有可能收到攻击。文章将<iframe>标签在HTML代码中出现的频率作为提取的一个特征。除此之外，本文还统计了其他可表现HTML特征的标签数量，见表2.2。

表2.2 HTML特征的标签

特征	标签 / 属性名称
HTML代码长度	None
内嵌页面的标签数量	<iframe>
支持隐藏的标签数量	style
包含链接的标签数量	href
带有刷新的标签数量	<meta>
含多媒体的标签数量	<embed>或<object>

2.2.3 JavaScript代码特征提取

2.2.4 HTTP请求特征提取

2.2.5 Text特征提取

3 模型选择与结果分析

3.1 特征集划分与模型选择

3.2 评估指标

通常情况下，人们将：正确率（Accuracy）、准确率（Precision）、召回率（Recall）、和F1-值（F1-score）作为二分类模型的评价指标，其详细的数学公式如(1)至(4)所示。其中，TP，FP，TN和FN分别为：真正例（TruePositive）；假正例（FalsePositive）；真负例（TrueNegative）；假负例（FalseNegative）。

$$Accuracy = \frac{TP+TN}{TP+FP+TN+FN} \quad (1)$$

$$Precision = \frac{TP}{TP+FP} \quad (2)$$

$$Recall = \frac{TP}{TP+FN} \quad (3)$$

$$F1 - Score = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (4)$$

$$Denominator = \frac{TP}{TP+FN} + \frac{TP}{TP+FP} \quad (4a)$$

$$F1 - Score = \frac{2 \cdot TP}{Denominator \cdot (TP+FP) \cdot (TP+FN)} \quad (4b)$$

4 恶意网页识别系统的设计与实现

4.1 系统框架设计

4.2 系统的实现

4.2.1 设计系统的语言选择

4.2.2 系统功能及界面

5 总结与展望

参考文献

- [1] 中国互联网络信息中心.第51次《中国互联网络发展状况统计报告》[EB/OL](2023-03-23).
- [2] 沙泓州,刘庆云,柳厅文等.恶意网页识别研究综述[J].计算机学报,2016,39(3):529-542.
- [3] FetteI,SadehN,TomasicA.Learning to detect phishing mails [C].Proceeding softhe 16th International Conference on World Wide Web,Banff,Canada,2007:649-656.
- [4]

致 谢

值此论文完成之际，谨向所有关心和支持我的人们致以诚挚的意！……………

附 录

附录A计算原始数据

附A1XXX数据